Université de Strasbourg
Master Mathématiques et Applications – Parcours Statistique

Titre du rapport de stage

Sous-titre si besoin

Yester MRTCHYAN

Année universitaire 2025–2026

Remerciements

Table des matières

Introduction **3**

1 Contexte et cadre du stage **4**
1.1 Présentation du sujet de recherche 4
1.2 Planification du stage 4
1.3 Principes du deep learning et du modèle d'identification utilisé 4
1.3.1 Apprentissage supervisé et réseaux de neurones 4
1.3.2 Le modèle de classification utilisé 4
1.3.3 Ré-entraînement (fine-tuning) 4

2 Données et méthodologie d'annotation **5**
2.1 Description de la base de données 5
2.2 Protocole d'annotation et de correction manuelle 5
2.3 Statistiques descriptives 5
2.3.1 Taux d'identification correcte 5
2.3.2 Analyse des scores de confiance 5
2.4 Ré-entraînement du modèle : évaluation du gain 5

3 Construction des matrices de proximité sociale **6**
3.1 Matrice estimée à partir des données annotées 6
3.2 Matrice de référence 6
3.3 Propriétés mathématiques des deux matrices 6

4 Comparaison statistique des deux matrices **7**
4.1 Problématique statistique 7
4.2 Présentation théorique de la méthode de comparaison 7
4.3 Vérification des conditions d'application 7
4.4 Résultats et interprétation 7

5 Discussion et limites **8**
5.1 Synthèse croisée des résultats 8
5.2 Limites de validité 8
5.3 Apport personnel et autonomie 8

Conclusion **9**

Bibliographie **9**

A Annexes **10**
A.1 Extraits de code 10
A.2 Captures d'écran de l'interface 10
A.3 Tableaux complémentaires 10

Introduction

Chapitre 1

Contexte et cadre du stage

L'Institut pluridisciplinaire Hubert Curien (IPHC) est un laboratoire de recherche du CNRS et de l'Université de Strasbourg. Differents axes de recherche existent dont le Département d'écologie, de physiologie et d'éthologie (DEPE). Ce dernier étudie les mécanismes permettant aux espèces animales de faire face aux contraintes de leur environnement à travers des approches d'écologie comportementale et d'écophysiologie, qu'elles soient fonctionnelles ou évolutives.

1.1 Présentation du sujet de recherche

1.2 Planification du stage

1.3 Principes du deep learning et du modèle d'identification utilisé

1.3.1 Apprentissage supervisé et réseaux de neurones

1.3.2 Le modèle de classification utilisé

Le modèle prend en entrée une image X_i et produit un vecteur de probabilités

$$\hat{p}(X_i) = (\hat{p}_1, \hat{p}_2, \ldots, \hat{p}_K), \qquad \sum_{k=1}^{K} \hat{p}_k = 1, \tag{1.1}$$

où K est le nombre d'individus connus dans la base. L'identité prédite est

$$\hat{Y}_i = \arg \max_{k \in \{1,\ldots,K\}} \hat{p}_k. \tag{1.2}$$

1.3.3 Ré-entraînement (fine-tuning)

Chapitre 2

Données et méthodologie d'annotation

2.1 Description de la base de données

2.2 Protocole d'annotation et de correction manuelle

2.3 Statistiques descriptives

2.3.1 Taux d'identification correcte

2.3.2 Analyse des scores de confiance

2.4 Ré-entraînement du modèle : évaluation du gain

Chapitre 3

Construction des matrices de proximité sociale

3.1 Matrice estimée à partir des données annotées

Soit $\hat{M}$ la matrice de proximité estimée, de taille $K \times K$, définie par

$$\hat{M}_{ij} = \frac{\text{nombre de co-occurrences observées entre } i \text{ et } j}{\text{normalisation}}. \tag{3.1}$$

3.2 Matrice de référence

3.3 Propriétés mathématiques des deux matrices

Chapitre 4

Comparaison statistique des deux matrices

4.1 Problématique statistique

4.2 Présentation théorique de la méthode de comparaison

4.3 Vérification des conditions d'application

4.4 Résultats et interprétation

Chapitre 5

Discussion et limites

5.1 Synthèse croisée des résultats

5.2 Limites de validité

5.3 Apport personnel et autonomie

Conclusion

Annexe A

Annexes

A.1 Extraits de code

```
# Exemple : calcul du taux d'identification correcte
correct = sum(1 for a in annotations if a["corrected_id"] == a["
    predicted_id"])
taux = correct / len(annotations)
```

A.2 Captures d'écran de l'interface

A.3 Tableaux complémentaires