Université de Strasbourg
Master Mathématiques et Applications – Parcours Statistique

Identification individuelle et analyse du réseau social de macaques japonais par apprentissage profond

Projet AI-SARU – Population de Koshima

Prénom NOM

Année universitaire 2025–2026

Remerciements

Table des matières

Introduction **3**

1 Méthodes de détection automatique par deep learning **4**
1.1 Introduction au machine learning et au deep learning 4
1.2 Principe de la détection d'objets et du modèle YOLO 5
1.3 Évaluation des performances du modèle 7
1.4 Utilisation de YOLO dans le cadre du projet 7

2 Données et prétraitement **9**
2.1 Présentation et acquisition des données 9
2.2 Organisation et préparation des données 9
2.3 Nettoyage et annotation des images 10
2.4 Correction et validation des détections 10

3 Construction des matrices de proximité sociale **11**
3.1 Détection des individus et évaluation des résultats 11
3.2 Extraction des coordonnées et calcul des distances 11
3.3 Construction de la matrice de proximité sociale à partir des détections 12
3.4 Construction de la matrice de référence à partir des observations de terrain . . . 12

4 Comparaison statistique des matrices **14**
4.1 Méthodologie de comparaison des matrices 14
4.2 Présentation théorique du test de Mantel 14
4.3 Application du test de Mantel et résultats 14
4.4 Interprétation des résultats 15

5 Discussion et perspectives **16**
5.1 Discussion des résultats 16
5.2 Limites et conditions d'application des méthodes 16
5.3 Perspectives d'amélioration 16

Conclusion générale **17**

Bibliographie **17**

A Annexes **18**
A.1 Extraits de code 18
A.2 Figures complémentaires 18
A.3 Tableaux complémentaires 18

Introduction

Contexte scientifique et présentation du projet

Contexte du stage et problématique

Objectifs du stage

Organisation du rapport

Chapitre 1

Méthodes de détection automatique par deep learning

1.1 Introduction au machine learning et au deep learning

Apprentissage supervisé. On se place dans le cadre de l'apprentissage supervisé : on dispose d'un ensemble d'exemples $(X_i, Y_i)_{i=1}^n$, où X_i est une image et $Y_i \in \{1, \dots, K\}$ l'identité connue de l'individu photographié parmi les K individus de la population étudiée. L'objectif est d'estimer une fonction $\hat{f}_\theta$, paramétrée par θ, qui approche au mieux la relation entre X et Y. Il s'agit d'un problème de *classification*, la variable Y étant catégorielle (à distinguer d'un problème de régression, où Y serait continue).

Modèle de classification et fonction de perte. Pour une image X_i, le modèle produit un vecteur de probabilités

$$\hat{p}(X_i) = (\hat{p}_1, \dots, \hat{p}_K), \qquad \sum_{k=1}^{K} \hat{p}_k = 1, \tag{1.1}$$

et l'identité prédite est $\hat{Y}_i = \arg\max_k \hat{p}_k$.

L'apprentissage consiste à ajuster θ en minimisant une fonction de perte, l'entropie croisée :

$$\mathcal{L}(\theta) = -\frac{1}{n} \sum_{i=1}^{n} \log \hat{p}_{\theta, Y_i}(X_i). \tag{1.2}$$

Ce choix n'est pas arbitraire : sous l'hypothèse d'observations indépendantes, la vraisemblance du modèle s'écrit

$$\mathcal{V}(\theta) = \prod_{i=1}^{n} \hat{p}_{\theta, Y_i}(X_i), \tag{1.3}$$

et minimiser $\mathcal{L}(\theta)$ revient exactement à maximiser la log-vraisemblance $\log \mathcal{V}(\theta)$, à un facteur $-1/n$ près. L'entraînement du réseau de neurones s'interprète donc comme une **estimation par maximum de vraisemblance**.

L'opération de convolution. La fonction $\hat{f}_\theta$ est ici réalisée par un **réseau de neurones convolutif** (CNN). L'opération de base de ce type de réseau est la **convolution discrète** : un petit filtre (ou noyau) $W \in \mathbb{R}^{k \times k}$, de paramètres appartenant à θ, glisse sur l'image d'entrée X et produit une carte de caractéristiques F définie, pour chaque position (i, j), par

$$F(i, j) = \sum_{u=1}^{k} \sum_{v=1}^{k} W(u, v)\, X(i + u, j + v) \; + \; b, \tag{1.4}$$

où b est un biais. Ce résultat est ensuite transformé par une fonction d'activation non linéaire ϕ (typiquement la *ReLU*, $\phi(x) = \max(0, x)$), donnant une carte activée $\phi(F)$. Un réseau convolutif empile ainsi plusieurs couches de ce type : les premières couches détectent des motifs simples (contours, textures), les couches plus profondes combinent ces motifs en des représentations de plus haut niveau (formes de visage, motifs propres à un individu). L'ensemble des poids W et biais b de toutes les couches constitue le vecteur de paramètres θ à estimer.

Estimation des paramètres par descente de gradient. L'estimation de $\hat{\theta} = \arg\min_\theta \mathcal{L}(\theta)$ ne peut pas se faire par une formule fermée, la fonction $\mathcal{L}$ étant hautement non convexe et de très grande dimension (typiquement plusieurs millions de paramètres). On procède donc par **descente de gradient** : partant d'une valeur initiale $\theta^{(0)}$, on met à jour itérativement les paramètres dans la direction opposée au gradient de la perte,

$$\theta^{(t+1)} = \theta^{(t)} - \eta \, \nabla_\theta \mathcal{L}(\theta^{(t)}), \tag{1.5}$$

où $\eta > 0$ est le taux d'apprentissage (*learning rate*). En pratique, le gradient n'est pas calculé sur l'ensemble des n exemples à chaque itération (ce qui serait trop coûteux), mais sur un sous-échantillon aléatoire (un *batch*) : c'est la **descente de gradient stochastique** (SGD), ou l'une de ses variantes (Adam, RMSProp), utilisée en pratique par la quasi-totalité des réseaux de neurones, y compris YOLO. Le calcul du gradient $\nabla_\theta \mathcal{L}$, malgré la profondeur du réseau, est rendu possible par l'algorithme de **rétropropagation** (*backpropagation*), qui applique la règle de dérivation en chaîne couche par couche, depuis la sortie du réseau jusqu'à ses premiers paramètres.

Le **ré-entraînement** (*fine-tuning*) réalisé pendant le stage consiste précisément à reprendre cette procédure d'optimisation, non pas depuis une initialisation aléatoire $\theta^{(0)}$, mais depuis les paramètres déjà appris sur la population de Shodoshima, en poursuivant la descente de gradient sur les nouvelles données annotées de Koshima. Cette approche exploite le fait que les premières couches du réseau (détection de motifs visuels génériques) restent largement valides d'une population à l'autre, seules les couches les plus profondes nécessitant un réajustement substantiel pour s'adapter aux nouveaux individus.

1.2 Principe de la détection d'objets et du modèle YOLO

Le modèle utilisé pour la reconnaissance faciale des macaques est un modèle **YOLO** (*You Only Look Once*) [**?**]. Contrairement à un simple classifieur qui recevrait en entrée une image déjà recadrée sur un visage, YOLO est un modèle de **détection d'objets** : à partir d'une image complète, il prédit simultanément, en une seule passe du réseau,

- la **localisation** des objets présents (ici, les coordonnées des boîtes englobantes autour des visages détectés) ;
- la **classification** de chaque objet détecté, c'est-à-dire l'identité de l'individu parmi les K individus connus.

C'est ce mécanisme qui explique le fonctionnement observé dans l'interface d'annotation : pour chaque visage localisé, le modèle renvoie les identités candidates classées par score de confiance, ce score correspondant à la probabilité de classe $\hat{p}_k$ associée à la détection.

Découpage en grille. Le principe central de YOLO consiste à découper l'image d'entrée en une grille de $S \times S$ cellules. Chaque cellule est responsable de détecter un objet si le centre de cet objet tombe dans son emprise. L'ensemble de l'image est ainsi traité en une seule passe du réseau, contrairement aux approches plus anciennes qui balayaient l'image par fenêtres glissantes successives – d'où le nom de la méthode.

Mesure de qualité d'une détection : l'IoU. Pour évaluer si une boîte englobante prédite correspond bien à un objet réel, on utilise l'**intersection sur union** (IoU) entre la boîte prédite et la boîte de vérité terrain :

$$\mathrm{IoU} = \frac{\mathrm{aire}(\text{boîte prédite} \cap \text{boîte réelle})}{\mathrm{aire}(\text{boîte prédite} \cup \text{boîte réelle})} \in [0,1]. \tag{1.6}$$

Une IoU proche de 1 indique une boîte prédite quasiment identique à la boîte réelle ; une IoU proche de 0 indique une absence de recouvrement. Cette mesure sert à la fois à évaluer la qualité de la détection et, lors de l'entraînement, à déterminer quelle prédiction est associée à quel objet réel.

Pour chaque boîte prédite, le réseau produit également un score de confiance $\hat{c} \in [0,1]$, qui approche le produit

$$\hat{c} \approx \Pr(\text{objet présent dans la cellule}) \times \mathrm{IoU}(\text{boîte prédite}, \text{boîte réelle}). \tag{1.7}$$

Ainsi, une détection n'est retenue que si un objet est jugé présent *et* que la boîte prédite recouvre bien l'objet réel.

Filtrage des détections redondantes. Plusieurs cellules voisines peuvent proposer des boîtes qui se recouvrent fortement pour un même objet. Un post-traitement, la **suppression non-maximale** (NMS), élimine les doublons : parmi les boîtes qui se recouvrent fortement (IoU élevé entre elles), seule celle au score de confiance le plus élevé est conservée. C'est ce qui garantit qu'un même visage n'est détecté qu'une seule fois dans l'image finale.

Paramétrisation des boîtes par rapport aux ancres. YOLO ne prédit pas directement les coordonnées d'une boîte, mais un ajustement par rapport à une boîte de référence prédéfinie (*anchor box*), de largeur p_w et hauteur p_h, associée à la cellule de centre (c_x, c_y). Le réseau prédit quatre valeurs brutes (t_x, t_y, t_w, t_h), transformées en coordonnées réelles par :

$$b_x = \sigma(t_x) + c_x, \qquad b_y = \sigma(t_y) + c_y, \tag{1.8}$$

$$b_w = p_w\, e^{t_w}, \qquad b_h = p_h\, e^{t_h}, \tag{1.9}$$

où σ désigne la fonction sigmoïde, qui contraint le centre prédit à rester dans la cellule considérée, tandis que l'exponentielle garantit la positivité des largeur et hauteur prédites.

Fonction de perte composite, en détail. En notant $\mathbb{1}_{ij}^{\mathrm{obj}}$ l'indicatrice valant 1 si la cellule (i,j) contient effectivement le centre d'un objet réel (et 0 sinon), et $\mathbb{1}_{ij}^{\mathrm{noobj}} = 1 - \mathbb{1}_{ij}^{\mathrm{obj}}$, la perte totale se décompose en trois termes :

$$\mathcal{L}_{\mathrm{YOLO}}(\theta) = \mathcal{L}_{\mathrm{loc}}(\theta) + \mathcal{L}_{\mathrm{obj}}(\theta) + \mathcal{L}_{\mathrm{cls}}(\theta), \tag{1.10}$$

$$\mathcal{L}_{\mathrm{loc}} = \lambda_{\mathrm{coord}} \sum_{i,j} \mathbb{1}_{ij}^{\mathrm{obj}} \Big[(b_x - \hat{b}_x)^2 + (b_y - \hat{b}_y)^2 + (\sqrt{b_w} - \sqrt{\hat{b}_w})^2 + (\sqrt{b_h} - \sqrt{\hat{b}_h})^2 \Big], \tag{1.11}$$

$$\mathcal{L}_{\mathrm{obj}} = \sum_{i,j} \mathbb{1}_{ij}^{\mathrm{obj}} (\hat{c}_{ij} - c_{ij})^2 \;+\; \lambda_{\mathrm{noobj}} \sum_{i,j} \mathbb{1}_{ij}^{\mathrm{noobj}}\, \hat{c}_{ij}^2, \tag{1.12}$$

$$\mathcal{L}_{\mathrm{cls}} = \sum_{i,j} \mathbb{1}_{ij}^{\mathrm{obj}} \sum_{k=1}^{K} -\log \hat{p}_{ij,k}. \tag{1.13}$$

où $\mathcal{L}_{\text{loc}}$ pénalise l'erreur de régression sur les coordonnées de la boîte englobante, $\mathcal{L}_{\text{obj}}$ pénalise l'erreur sur le score de confiance $\hat{c}$ défini précédemment, et $\mathcal{L}_{\text{cls}}$ retrouve exactement le terme d'entropie croisée établi en 1.1, restreint ici aux cellules contenant réellement un objet.

Le passage par la racine carrée sur la largeur et la hauteur dans $\mathcal{L}_{\text{loc}}$ est un choix technique : il pénalise proportionnellement moins une erreur donnée sur une grande boîte que sur une petite boîte (une erreur de 10 pixels est plus grave, relativement, pour une petite boîte que pour une grande). Le poids $\lambda_{\text{noobj}} < 1$ réduit l'importance des cellules sans objet dans la perte, très majoritaires dans une image typique, pour éviter qu'elles ne dominent l'apprentissage face aux rares cellules contenant effectivement un visage.

L'interprétation en termes de maximum de vraisemblance établie en 1.1 reste valable, mais concerne uniquement la composante $\mathcal{L}_{\text{cls}}$ de cette perte composite : c'est elle qui correspond à l'estimation de l'identité de l'individu, tandis que $\mathcal{L}_{\text{loc}}$ et $\mathcal{L}_{\text{obj}}$ relèvent respectivement d'un problème de régression aux moindres carrés et d'un problème de détection binaire (présence/absence d'objet), non directement concernés par la classification des identités.

Note : les versions plus récentes de YOLO (v3 et suivantes) utilisent des variantes plus sophistiquées, notamment pour $\mathcal{L}_{loc}$ (perte de type CIoU) ; la formulation ci-dessus correspond à la version originale, suffisante pour comprendre le principe général de la méthode.

1.3 Évaluation des performances du modèle

Cette section présente, sur le plan théorique, les outils statistiques permettant d'évaluer la qualité des prédictions d'un modèle de classification. Leur application aux données réelles du stage est présentée au chapitre 3, section 3.1.

Matrice de confusion. Pour un problème de classification à K classes, la **matrice de confusion** C est une matrice $K \times K$ dont l'entrée C_{kl} compte le nombre d'observations dont l'identité réelle est k et l'identité prédite est l. La diagonale de C regroupe les prédictions correctes ; les termes hors diagonale correspondent aux erreurs, et leur répartition renseigne sur les confusions systématiques entre certains individus.

Métriques dérivées. À partir de la matrice de confusion, on définit pour chaque individu k :

$$\text{précision}_k = \frac{C_{kk}}{\sum_l C_{lk}} \quad \text{(parmi les prédictions "}k\text{", combien sont correctes)}, \tag{1.14}$$

$$\text{rappel}_k = \frac{C_{kk}}{\sum_l C_{kl}} \quad \text{(parmi les individus réellement "}k\text{", combien sont bien retrouvés)}, \tag{1.15}$$

ainsi que le taux d'exactitude global (*accuracy*) :

$$\text{exactitude} = \frac{\sum_k C_{kk}}{\sum_{k,l} C_{kl}}. \tag{1.16}$$

1.4 Utilisation de YOLO dans le cadre du projet

La problématique posée – détecter des macaques dans une vidéo, puis en déduire une mesure de similarité/proximité entre individus – requiert précisément les deux capacités offertes conjointement par YOLO : la **localisation** (indispensable pour extraire les coordonnées nécessaires au calcul ultérieur de la proximité spatiale, cf. chapitre 3) et la **classification** (nécessaire pour savoir quel individu est localisé à quel endroit). Le traitement en une seule passe du réseau permet par ailleurs un traitement de vidéos entières, comportant plusieurs dizaines de milliers de frames, à un coût de calcul raisonnable – un critère déterminant compte tenu du volume de

données vidéo disponible sur la population de Koshima (cf. chapitre 2). Le choix de ce modèle, opéré par l'encadrant du stage en amont de celui-ci sur la base de résultats déjà obtenus sur la population de Shodoshima, apparaît ainsi pleinement justifié au regard de la problématique.

Chapitre 2

Données et prétraitement

2.1 Présentation et acquisition des données

2.2 Organisation et préparation des données

Les prédictions du modèle sont stockées au format JSON, selon une structure proche du format COCO, organisée en trois blocs :

- `images` : une entrée par frame vidéo (identifiant, nom de fichier, dimensions) ;
- `annotations` : une entrée par détection, contenant les coordonnées de la boîte englobante (`bbox`), l'identifiant de *track* (`track_id`), le score de confiance de la meilleure prédiction (`confidence`), l'identité retenue (`category_id`, `category_name`), ainsi que le détail des cinq identités les plus probables et leurs scores respectifs (`extended_classification`, top1 à top5) ;
- `categories` : la liste des individus connus de la population étudiée (43 individus recensés dans l'exemple ci-dessous).

Un fichier JSON de ce type est généré par vidéo traitée. À titre d'illustration, un fichier correspondant à une vidéo de la population de Koshima contient :

- 68 332 frames et 46 647 détections (soit en moyenne 0,68 détection par frame, la plupart des frames ne contenant pas ou un seul individu détecté) ;
- 1 270 *tracks* distincts, de taille très variable (médiane : 11 frames, maximum : 1 171 frames) ;
- une confiance moyenne de la meilleure prédiction de 0,750 (écart-type : 0,092) ;
- une forte hétérogénéité du nombre de détections par individu, allant de 26 (individu le moins représenté) à 2 670 (individu le plus représenté) ;
- une proportion notable de détections ambiguës : dans 29,6 % des cas, l'écart de score entre la première et la deuxième identité proposée est inférieur à 0,1, signe d'une identification incertaine du modèle.

Remarque méthodologique : ce fichier ne contient pas de champ distinguant explicitement une identité *corrigée manuellement* d'une identité simplement *prédite par le modèle* – `category_name` correspond dans tous les cas observés à la première proposition (*top1*) de `extended_classification`. Une clarification reste nécessaire pour déterminer si les fichiers disponibles correspondent aux prédictions avant ou après le ré-entraînement du modèle sur les données corrigées de Koshima ; cette question est discutée en section 5.2.

Les vidéos sont par ailleurs numérisées en une séquence de frames à intervalle régulier (échantillonnage temporel), chaque frame étant redimensionnée à une résolution fixe avant d'être présentée en entrée du réseau.

2.3 Nettoyage et annotation des images

2.4 Correction et validation des détections

Afin d'évaluer objectivement la qualité des identifications produites par le modèle, un échantillon d'images est relu manuellement : pour chaque image de l'échantillon, l'identité réelle de l'individu est reportée dans un tableau, en regard de l'identité prédite par le modèle. Ce tableau constitue la **vérité terrain** nécessaire au calcul des métriques d'évaluation présentées au chapitre 1, section 1.3, et appliquées au chapitre 3.

Chapitre 3

Construction des matrices de proximité sociale

3.1 Détection des individus et évaluation des résultats

Consolidation de l'identité par *track*. Les détections ne sont pas traitées indépendamment image par image : elles sont regroupées en *tracks*, c'est-à-dire des séquences de détections correspondant à un même individu suivi sur plusieurs frames consécutives. Pour un track t, on cumule sur toutes ses frames les scores de confiance associés à chaque identité candidate k :

$$S_t(k) = \sum_{\text{frame } f \in t} \text{score}_f(k). \tag{3.1}$$

L'identité retenue pour le track est celle qui maximise ce score cumulé, sous deux conditions de fiabilité :

— un support relatif suffisant, $\dfrac{\max_k S_t(k)}{\sum_k S_t(k)} \geq \tau_{\text{support}}$ (seuil par défaut : 60%) ;

— un nombre minimal de frames dans le track (par défaut : 3).

Cette consolidation par vote pondéré agrégé rend l'identification plus robuste qu'une décision frame par frame, chaque frame individuelle pouvant être bruitée.

Résultats d'évaluation.

3.2 Extraction des coordonnées et calcul des distances

Pour deux individus a et b détectés dans une même frame, on note $(c_{x,a}, c_{y,a})$ et $(c_{x,b}, c_{y,b})$ les centres de leurs boîtes de détection respectives. La distance centre-centre s'écrit

$$d_{ab} = \sqrt{(c_{x,a} - c_{x,b})^2 + (c_{y,a} - c_{y,b})^2}. \tag{3.2}$$

Cette distance en pixels ne suffit pas à elle seule, car elle ne tient pas compte de la profondeur : un même écart en pixels peut correspondre à une grande distance réelle si les individus sont loin de la caméra, ou une faible distance s'ils en sont proches. La hauteur de la boîte de détection sert de proxy à l'échelle apparente de l'individu, corrigée d'un facteur $\alpha(\text{âge})$ (les individus jeunes, plus petits, sont sous-corrigés sinon) :

$$h^{\text{corr}} = h \times \alpha(\text{âge}). \tag{3.3}$$

La distance normalisée est alors

$$d_{ab}^{\text{norm}} = \frac{d_{ab}}{\max(h_a^{\text{corr}}, h_b^{\text{corr}})}. \tag{3.4}$$

Un ratio de taille des aires corrigées sert de garde-fou contre les incompatibilités de profondeur :

$$r_{ab} = \frac{\max(\text{aire}_a^{\text{corr}}, \text{aire}_b^{\text{corr}})}{\min(\text{aire}_a^{\text{corr}}, \text{aire}_b^{\text{corr}})}. \tag{3.5}$$

Si r_{ab} dépasse un seuil τ_{ratio}, la paire est jugée trop incertaine en profondeur et exclue.

La paire (a, b) est déclarée **proche** dans la frame si

$$d_{ab}^{\text{norm}} \leq \tau_{\text{dist}} \quad \text{et} \quad r_{ab} \leq \tau_{\text{ratio}}. \tag{3.6}$$

3.3 Construction de la matrice de proximité sociale à partir des détections

Agrégation frame vers vidéo. Pour chaque vidéo v et chaque paire (a, b) co-détectée, on calcule la proportion de frames où la paire est proche :

$$\text{score}_v(a, b) = \frac{\text{nombre de frames "proches"}}{\text{nombre de frames co-détectées valides}}. \tag{3.7}$$

Agrégation vidéo vers matrice globale. Les frames d'une même vidéo ne constituent pas des observations indépendantes : deux individus filmés proches pendant 30 secondes ne fournissent pas autant d'information que 900 observations indépendantes de proximité, mais plutôt une unique situation répétée à haute fréquence d'échantillonnage. Pour limiter le poids disproportionné des vidéos longues, chaque vidéo se voit attribuer un poids plafonné :

$$w_v = \min(\text{nombre de frames co-détectées valides}_v,\ w_{\max}), \tag{3.8}$$

avec $w_{\max} = 900$ par défaut (soit 30 secondes à 30 images/seconde).

La matrice de proximité globale $\hat{M}$ est alors une moyenne pondérée des scores vidéo :

$$\hat{M}_{ab} = \frac{\sum_v w_v \cdot \text{score}_v(a, b)}{\sum_v w_v}. \tag{3.9}$$

Propriétés de la matrice obtenue.

3.4 Construction de la matrice de référence à partir des observations de terrain

La matrice de référence M^* est construite à partir d'observations de terrain réalisées directement par des chercheurs, sur la même période temporelle que les vidéos utilisées pour le ré-entraînement du modèle. Contrairement à la matrice estimée $\hat{M}$, qui repose uniquement sur la fréquence de proximité spatiale détectée automatiquement, M^* agrège plusieurs dimensions du lien social observées sur le terrain : la fréquence de coprésence, les interactions de toilettage (*grooming*), les relations de dominance, ainsi que les liens de parenté entre individus. M^*_{ab} traduit ainsi une intensité globale de proximité sociale entre les individus a et b, au sens large.

Cette différence de nature entre les deux matrices doit être nuancée. La matrice estimée $\hat{M}$ ne mesure explicitement qu'une proximité spatiale ; elle ne distingue pas la nature du lien à l'origine de cette proximité. Cependant, les épisodes de grooming ou de jeu, qui impliquent par nature un contact ou une grande proximité physique entre les individus concernés, se traduisent directement par des scores de proximité élevés dans $\hat{M}$: ces comportements sont donc captés *indirectement* par la mesure spatiale, sans être reconnus ou différenciés en tant que tels. $\hat{M}$ ne peut en revanche

pas distinguer une proximité spatiale « fortuite » (par exemple deux individus qui se nourrissent côte à côte sans interaction sociale particulière) d'une proximité liée à un comportement social significatif, ni capter des liens sociaux ne se traduisant pas par une coprésence spatiale fréquente (par exemple un lien de parenté entre deux individus qui se croisent rarement). La matrice de référence M^*, construite à partir d'observations de terrain intégrant explicitement la nature des interactions (grooming, dominance, parenté), permet cette distinction que $\hat{M}$ ne fait pas. Cette asymétrie doit être gardée à l'esprit dans l'interprétation de leur comparaison (cf. section 5.2).

Chapitre 4

Comparaison statistique des matrices

4.1 Méthodologie de comparaison des matrices

Les entrées de la matrice $\hat{M}$ (et de la matrice de référence M^*) ne sont pas indépendantes entre elles : la ligne associée à un individu a particulièrement sociable sera globalement élevée sur toute la ligne, car les valeurs $\hat{M}_{ab}$ et $\hat{M}_{ac}$ partagent la même dépendance à a. Un test de corrélation classique (Pearson), qui suppose l'indépendance des observations, ne peut donc pas être appliqué directement entre les entrées des deux matrices. Une méthode adaptée à cette structure de dépendance est nécessaire : le test de Mantel.

4.2 Présentation théorique du test de Mantel

Le **test de Mantel** [**?**] est spécifiquement conçu pour comparer deux matrices de distance ou de proximité définies sur le même ensemble d'unités (ici, les K individus).

Statistique de test. On considère la corrélation (par exemple de Pearson) entre les entrées des deux matrices, restreinte aux paires distinctes (a, b), $a \neq b$:

$$Z_{\text{obs}} = \text{corr}\big(\{\hat{M}_{ab}\}_{a<b},\ \{M^*_{ab}\}_{a<b}\big). \tag{4.1}$$

Hypothèse nulle et test par permutation. L'hypothèse nulle H_0 postule l'absence d'association entre les deux structures de proximité. Comme les entrées d'une même matrice ne sont pas indépendantes (une ligne entière dépend de la sociabilité globale d'un individu), la distribution théorique usuelle de la statistique de corrélation ne s'applique pas. On construit donc la distribution de Z sous H_0 par **permutation** :

1. on permute aléatoirement l'ordre des individus (lignes et colonnes simultanément) dans l'une des deux matrices, par exemple M^*, donnant M^*_π pour une permutation π ;
2. on recalcule la statistique de corrélation Z_π entre $\hat{M}$ et M^*_π ;
3. on répète l'opération un grand nombre de fois (typiquement 999 ou 9999 permutations), donnant une distribution empirique $\{Z_\pi\}$ sous H_0.

La p-valeur empirique est alors la proportion de permutations pour lesquelles Z_π est au moins aussi extrême que Z_{obs} :

$$p = \frac{1 + \#\{\pi : |Z_\pi| \geq |Z_{\text{obs}}|\}}{1 + \text{nombre de permutations}}. \tag{4.2}$$

4.3 Application du test de Mantel et résultats

Vérification des conditions d'application.

— Les deux matrices doivent être définies sur le même ensemble d'individus, avec le même ordre de lignes/colonnes avant permutation.
— Le nombre de permutations doit être suffisant pour estimer précisément la p-valeur (au minimum quelques centaines).
— Les valeurs manquantes (paires jamais co-détectées dans $\hat{M}$) doivent être traitées explicitement (exclusion de la paire dans les deux matrices, ou imputation à justifier).
— Le test de Mantel suppose que la structure de dépendance interne à chaque matrice est correctement neutralisée par la permutation conjointe des lignes/colonnes – ce qui est le cas ici, la permutation appliquée à un individu déplace simultanément toute sa ligne et sa colonne.

Résultats obtenus.

4.4 Interprétation des résultats

Chapitre 5

Discussion et perspectives

5.1 Discussion des résultats

5.2 Limites et conditions d'application des méthodes

5.3 Perspectives d'amélioration

Conclusion générale

Annexe A

Annexes

A.1 Extraits de code

```
def evaluate_pair_in_frame(a, b, dist_thresh_norm, size_ratio_thresh):
    dist_norm = distance(a, b) / max(a["corrected_h"], b["corrected_h"])
    size_ratio = max(a["aire"], b["aire"]) / min(a["aire"], b["aire"])
    close = (dist_norm <= dist_thresh_norm) and (size_ratio <=
        size_ratio_thresh)
    return close
```

A.2 Figures complémentaires

A.3 Tableaux complémentaires