Université de Strasbourg
Master Mathématiques et Applications – Parcours Statistique

Identification individuelle et analyse du réseau social de macaques japonais par apprentissage profond

Projet AI-SARU – Population de Koshima

Prénom NOM

Année universitaire 2025–2026

Remerciements

Table des matières

Introduction **3**

1 Méthodes de détection automatique par apprentissage profond **4**
1.1 Introduction à l'apprentissage supervisé et à l'apprentissage profond 4
1.2 Détection d'objets et principe général du modèle YOLO 6
1.3 Évaluation statistique des performances du modèle 8
1.4 Application du modèle YOLO au projet 9

2 Données et prétraitement **10**
2.1 Présentation et acquisition des données 10
2.2 Organisation et préparation des données 11
2.3 Nettoyage et annotation des images 11
2.4 Correction et validation des détections 12

3 Construction de la matrice de proximité sociale **14**
3.1 Construction des observations individuelles 14
3.2 Extraction des coordonnées et calcul des distances 15
3.3 Construction de la matrice de proximité sociale 17

4 Comparaison statistique des matrices **20**
4.1 Méthodologie de comparaison des matrices 20
4.2 Présentation théorique du test de Mantel 20
4.3 Application du test de Mantel et résultats 20
4.4 Interprétation des résultats 21

5 Discussion et perspectives **22**
5.1 Discussion des résultats 22
5.2 Limites et conditions d'application des méthodes 22
5.3 Perspectives d'amélioration 22

Conclusion générale **23**

Bibliographie **23**

A Annexes **24**
A.1 Extraits de code 24
A.2 Figures complémentaires 24
A.3 Tableaux complémentaires 24

Introduction

Contexte scientifique et présentation du projet

Le stage s'est déroulé à l'Institut Pluridisciplinaire Hubert Curien (IPHC), unité mixte de recherche du CNRS et de l'Université de Strasbourg (UMR 7178), au sein du Département d'Écologie, Physiologie et Éthologie (DEPE). Ce département étudie les stratégies adaptatives mises en œuvre par les espèces animales pour faire face aux contraintes de leur environnement, à travers des approches d'écologie comportementale et d'écophysiologie, tant fonctionnelles qu'évolutives.

C'est dans ce cadre que s'inscrit le projet AI-SARU, dont l'objectif est de transformer des enregistrements vidéo bruts de populations de macaques japonais en données éthologiques directement exploitables scientifiquement, via une chaîne de traitement automatisée combinant détection des comportements, reconnaissance individuelle des animaux, et mesure de leur proximité sociale. L'automatisation de ces tâches, traditionnellement réalisées par observation humaine directe sur le terrain, répond à un besoin méthodologique bien identifié dans la littérature : Schofield *et al.* [**?**] ont notamment démontré, sur une population de chimpanzés sauvages suivie pendant 14 ans, qu'un pipeline entièrement automatisé de détection, suivi et reconnaissance faciale par apprentissage profond permet d'atteindre une précision d'identification supérieure à 92%, tout en traitant des volumes de données (plusieurs millions de détections) hors de portée d'un traitement manuel. Leurs travaux illustrent également l'intérêt de regrouper les détections en *tracks* avant de statuer sur l'identité d'un individu plutôt que de décider image par image, une approche directement reprise dans le pipeline AI-SARU (cf. chapitre 3).

Contexte du stage et problématique

Objectifs du stage

Organisation du rapport

“‘latex

Chapitre 1

Méthodes de détection automatique par apprentissage profond

Ce chapitre présente les principaux outils mathématiques et statistiques nécessaires à la compréhension du modèle utilisé dans le cadre du projet. L'objectif n'est pas de décrire exhaustivement l'architecture de YOLO, mais d'expliquer les mécanismes qui permettent de localiser un visage dans une image, de lui attribuer une identité et d'évaluer la qualité des prédictions obtenues.

1.1 Introduction à l'apprentissage supervisé et à l'apprentissage profond

Cadre de l'apprentissage supervisé. On se place dans le cadre de l'apprentissage supervisé. On dispose d'un échantillon d'apprentissage

$$\mathcal{D}_n = \{(X_i, Y_i)\}_{i=1}^n \,, \tag{1.1}$$

où X_i désigne une image et où $Y_i \in \{1, \ldots, K\}$ représente l'identité connue de l'individu présent dans cette image, parmi les K individus de la population étudiée.

L'objectif est de construire une fonction de prédiction $\widehat{f}_\theta$, dépendant d'un ensemble de paramètres θ, telle que

$$\widehat{Y}_i = \widehat{f}_\theta(X_i) \tag{1.2}$$

soit aussi proche que possible de l'identité réelle Y_i.

Il s'agit d'un problème de classification supervisée multiclasse, puisque la variable à prédire est qualitative et peut prendre plus de deux modalités. Cette situation se distingue d'un problème de régression, dans lequel la variable réponse est quantitative.

Sortie probabiliste du modèle. Pour une image X_i, le réseau produit généralement un vecteur de scores qui est transformé en probabilités estimées :

$$\widehat{\boldsymbol{p}}_\theta(X_i) = (\widehat{p}_{\theta,1}(X_i), \ldots, \widehat{p}_{\theta,K}(X_i)) \,, \tag{1.3}$$

avec

$$\widehat{p}_{\theta,k}(X_i) \geq 0, \qquad \sum_{k=1}^{K} \widehat{p}_{\theta,k}(X_i) = 1. \tag{1.4}$$

L'identité prédite est alors celle dont la probabilité estimée est la plus élevée :

$$\widehat{Y}_i = \underset{k\in\{1,\dots,K\}}{\arg\max}\ \widehat{p}_{\theta,k}(X_i). \tag{1.5}$$

Ces probabilités permettent non seulement de fournir une prédiction, mais également de quantifier le degré de confiance associé aux différentes identités candidates.

Fonction de perte et maximum de vraisemblance. Dans un problème de classification multiclasse, une fonction de perte couramment utilisée est l'entropie croisée. Elle s'écrit

$$\mathcal{L}_{\text{cls}}(\theta) = -\frac{1}{n}\sum_{i=1}^{n} \log\left(\widehat{p}_{\theta,Y_i}(X_i)\right). \tag{1.6}$$

Cette fonction pénalise fortement les situations dans lesquelles le modèle attribue une faible probabilité à la classe réelle.

D'un point de vue statistique, son utilisation peut être reliée au principe du maximum de vraisemblance. Sous l'hypothèse que les observations sont indépendantes conditionnellement aux paramètres du modèle, la vraisemblance s'écrit

$$\mathcal{V}(\theta) = \prod_{i=1}^{n} \widehat{p}_{\theta,Y_i}(X_i). \tag{1.7}$$

La log-vraisemblance est donc

$$\log \mathcal{V}(\theta) = \sum_{i=1}^{n} \log\left(\widehat{p}_{\theta,Y_i}(X_i)\right). \tag{1.8}$$

Minimiser l'entropie croisée définie dans l'équation (1.6) revient ainsi à maximiser la log-vraisemblance, à un facteur multiplicatif négatif près. L'apprentissage du classifieur peut donc être interprété comme une estimation des paramètres par maximum de vraisemblance.

Réseaux de neurones convolutifs. Les images possèdent une structure spatiale : deux pixels voisins ont généralement davantage de relations qu'une paire de pixels très éloignés. Les réseaux de neurones convolutifs, ou CNN, exploitent cette structure à l'aide de filtres locaux.

Pour une image d'entrée X et un noyau W de dimension $q \times q$, une carte de caractéristiques peut être définie par

$$F(i,j) = \sum_{u=1}^{q}\sum_{v=1}^{q} W(u,v)X(i+u, j+v) + b, \tag{1.9}$$

où b est un biais.

En pratique, l'opération réalisée dans de nombreuses bibliothèques d'apprentissage profond correspond techniquement à une corrélation croisée, mais elle est habituellement appelée convolution dans la littérature sur les CNN.

Le résultat est ensuite transformé par une fonction d'activation non linéaire. Une fonction courante est la fonction ReLU :

$$\phi(x) = \max(0, x). \tag{1.10}$$

L'empilement de plusieurs couches permet au réseau d'apprendre des représentations de complexité croissante. Les premières couches extraient généralement des motifs locaux simples, comme les contours ou les textures, tandis que les couches plus profondes combinent ces informations pour former des représentations plus discriminantes.

Estimation des paramètres. Les paramètres du réseau sont estimés en recherchant une valeur $\widehat{\theta}$ minimisant la fonction de perte :

$$\widehat{\theta} = \arg\min_{\theta} \mathcal{L}(\theta). \tag{1.11}$$

Cette optimisation ne possède généralement pas de solution analytique, en raison du grand nombre de paramètres et de la non-convexité de la fonction de perte. Les paramètres sont donc mis à jour de manière itérative par une méthode fondée sur le gradient :

$$\theta^{(t+1)} = \theta^{(t)} - \eta \nabla_{\theta} \mathcal{L}\left(\theta^{(t)}\right), \tag{1.12}$$

où $\eta > 0$ est le taux d'apprentissage.

En pratique, le gradient est généralement estimé sur un sous-échantillon d'observations appelé *mini-batch*. Cette procédure conduit à la descente de gradient stochastique ou à l'une de ses variantes, telles qu'Adam. La rétropropagation permet ensuite de calculer efficacement les dérivées de la fonction de perte par rapport à l'ensemble des paramètres du réseau.

Dans le cadre d'un ré-entraînement ou *fine-tuning*, l'optimisation ne commence pas à partir de paramètres aléatoires. Elle s'appuie sur les paramètres d'un modèle préalablement entraîné, puis les adapte aux nouvelles données. Dans le projet étudié, le principe consiste à exploiter un modèle déjà ajusté sur une autre population de macaques, puis à le réadapter aux individus de la population de Koshima. Cette description devra toutefois être précisée à partir des informations exactes fournies par l'encadrant concernant le protocole d'entraînement effectivement utilisé.

1.2 Détection d'objets et principe général du modèle YOLO

Le modèle employé dans le projet appartient à la famille YOLO, acronyme de *You Only Look Once* [**?**]. Les modèles de cette famille sont conçus pour effectuer une détection d'objets directement à partir d'une image complète.

Contrairement à un classifieur recevant une image déjà recadrée, un détecteur doit résoudre simultanément plusieurs tâches :

— déterminer si un objet d'intérêt est présent ;
— localiser cet objet à l'aide d'une boîte englobante ;
— attribuer une classe à l'objet localisé.

Dans le cadre du projet, la localisation permet d'obtenir les coordonnées des visages détectés, tandis que la classification permet d'associer chaque visage à une identité candidate.

Représentation d'une boîte englobante. Une boîte englobante peut être représentée par son centre et ses dimensions :

$$B = (c_x, c_y, w, h), \tag{1.13}$$

où (c_x, c_y) désigne le centre de la boîte, w sa largeur et h sa hauteur.

Elle peut également être décrite par les coordonnées de ses coins :

$$B = (x_{\min}, y_{\min}, x_{\max}, y_{\max}). \tag{1.14}$$

Ces informations sont particulièrement importantes dans ce projet, car les coordonnées des boîtes seront ensuite utilisées pour calculer une mesure de distance entre les individus détectés.

Prédiction en une seule étape. Le principe général de YOLO consiste à produire, lors d'une même évaluation du réseau, les prédictions de localisation, de présence d'objet et de classification. Cette approche se distingue des anciennes méthodes en deux étapes, qui généraient d'abord des régions candidates avant de les classifier séparément.

Le traitement conjoint de l'image rend cette famille de modèles adaptée à l'analyse de vidéos comportant un nombre important d'images successives.

Les détails précis de l'architecture, notamment le recours à une grille, à des boîtes d'ancrage ou à une représentation sans ancres, dépendent de la version de YOLO utilisée. Ils ne doivent donc être décrits dans le rapport qu'après identification exacte de la version et du paramétrage employés dans le projet.

Intersection sur union. La qualité géométrique d'une boîte prédite peut être évaluée à l'aide de l'intersection sur union, notée IoU. Pour une boîte prédite B_{pred} et une boîte de référence B_{ref}, elle est définie par

$$\text{IoU}\left(B_{\text{pred}}, B_{\text{ref}}\right) = \frac{\text{aire}\left(B_{\text{pred}} \cap B_{\text{ref}}\right)}{\text{aire}\left(B_{\text{pred}} \cup B_{\text{ref}}\right)}. \tag{1.15}$$

Cette quantité appartient à l'intervalle $[0, 1]$. Une valeur proche de 1 indique un fort recouvrement entre la boîte prédite et la boîte de référence, tandis qu'une valeur proche de 0 correspond à un faible recouvrement.

Dans une procédure d'évaluation, une détection est généralement considérée comme correctement localisée lorsque son IoU dépasse un seuil fixé. La valeur exacte de ce seuil doit être précisée si elle a été utilisée dans le projet.

Scores de confiance et filtrage des prédictions. Chaque détection est associée à un ou plusieurs scores représentant notamment la confiance du modèle dans la présence d'un objet et dans son appartenance à une classe.

Après la prédiction, un seuil de confiance peut être appliqué afin d'écarter les détections jugées trop incertaines. Un traitement supplémentaire est également nécessaire lorsque plusieurs boîtes se recouvrent fortement autour d'un même objet.

La suppression non maximale, ou NMS, consiste à conserver la boîte ayant le score le plus élevé, puis à supprimer les autres boîtes dont le recouvrement avec celle-ci dépasse un seuil donné. Cette procédure réduit le nombre de détections redondantes.

Fonction de perte d'un détecteur. L'entraînement d'un détecteur d'objets repose généralement sur une fonction de perte composée de plusieurs termes :

$$\mathcal{L}_{\text{det}} = \lambda_{\text{loc}}\mathcal{L}_{\text{loc}} + \lambda_{\text{obj}}\mathcal{L}_{\text{obj}} + \lambda_{\text{cls}}\mathcal{L}_{\text{cls}}, \tag{1.16}$$

où :

— $\mathcal{L}_{\text{loc}}$ mesure l'erreur de localisation des boîtes englobantes ;
— $\mathcal{L}_{\text{obj}}$ mesure l'erreur relative à la présence ou à l'absence d'un objet ;
— $\mathcal{L}_{\text{cls}}$ mesure l'erreur de classification ;
— les coefficients λ_{loc}, λ_{obj} et λ_{cls} règlent l'importance relative de ces composantes.

La forme exacte de chacune de ces composantes dépend de la version de YOLO utilisée. Certaines versions emploient, par exemple, des fonctions de perte fondées sur l'IoU ou sur des variantes telles que la GIoU, la DIoU ou la CIoU pour évaluer la localisation des boîtes.

Il serait donc incorrect de présenter une fonction de perte détaillée comme étant celle du modèle du projet sans avoir vérifié la version exacte du réseau. L'équation (1.16) fournit ici une représentation générale du principe d'optimisation.

1.3 Évaluation statistique des performances du modèle

L'évaluation du modèle doit distinguer deux aspects :
— la qualité de la localisation des visages ;
— la qualité de l'identification individuelle.

La localisation peut être étudiée à l'aide de l'IoU et de métriques propres à la détection d'objets. L'identification individuelle peut être évaluée à partir d'une matrice de confusion construite en comparant les identités prédites aux identités réelles.

Matrice de confusion. Pour un problème comportant K individus, la matrice de confusion est une matrice $C = (C_{kl})_{1 \leq k,l \leq K}$ dans laquelle

$$C_{kl} = \text{nombre d'observations d'identité réelle } k \text{ prédites comme } l. \tag{1.17}$$

Les valeurs diagonales C_{kk} correspondent aux identifications correctes, tandis que les valeurs hors diagonale décrivent les erreurs de classification.

La matrice permet notamment d'identifier les couples d'individus fréquemment confondus par le modèle.

Précision et rappel. Pour un individu k, la précision est définie par

$$\text{Prcision}_k = \frac{C_{kk}}{\sum_{l=1}^{K} C_{lk}}. \tag{1.18}$$

Elle mesure la proportion de prédictions associées à l'identité k qui sont effectivement correctes.

Le rappel est défini par

$$\text{Rappel}_k = \frac{C_{kk}}{\sum_{l=1}^{K} C_{kl}}. \tag{1.19}$$

Il mesure la proportion d'observations réellement associées à l'individu k qui sont correctement reconnues.

F1-score. Le F1-score est la moyenne harmonique de la précision et du rappel :

$$F1_k = 2\frac{\text{Prcision}_k \, \text{Rappel}_k}{\text{Prcision}_k + \text{Rappel}_k}. \tag{1.20}$$

Cette métrique est utile lorsqu'un compromis entre précision et rappel est recherché. Elle doit toutefois être interprétée avec précaution lorsque certains individus sont beaucoup plus représentés que d'autres.

Exactitude globale. Le taux d'exactitude global, ou *accuracy*, est défini par

$$\text{Exactitude} = \frac{\sum_{k=1}^{K} C_{kk}}{\sum_{k=1}^{K}\sum_{l=1}^{K} C_{kl}}. \tag{1.21}$$

Il représente la proportion totale de prédictions correctes.

Cependant, lorsque les effectifs diffèrent fortement entre individus, cette mesure peut être dominée par les classes les plus représentées. Il est donc préférable de compléter l'exactitude globale par des métriques calculées individu par individu, puis éventuellement par leurs moyennes macro :

$$\text{Rappel}_{\text{macro}} = \frac{1}{K} \sum_{k=1}^{K} \text{Rappel}_k \,. \tag{1.22}$$

Cette moyenne accorde le même poids à chaque individu, indépendamment de son nombre d'observations.

Ensemble d'évaluation. Afin que les métriques mesurent réellement la capacité de généralisation du modèle, elles devraient idéalement être calculées sur des données n'ayant pas servi à son entraînement.

Si les mêmes images sont utilisées pour entraîner puis évaluer le réseau, les performances risquent d'être surestimées. La constitution de l'échantillon de vérité terrain et sa relation avec les données d'entraînement devront donc être décrites précisément dans le chapitre 2.

L'application de ces métriques aux résultats obtenus pendant le stage sera présentée au chapitre 3, dans la section **??**.

1.4 Application du modèle YOLO au projet

Le choix d'un modèle de détection de la famille YOLO a été effectué par l'encadrant du stage avant le début de celui-ci. Ce choix s'appuyait notamment sur des résultats déjà obtenus sur une autre population de macaques.

Son utilisation répond à deux besoins complémentaires du projet.

Premièrement, la localisation des visages permet d'extraire les coordonnées des boîtes englobantes. Ces coordonnées constituent les informations nécessaires au calcul ultérieur des distances spatiales entre individus.

Deuxièmement, la classification permet d'associer chaque boîte englobante à une identité. Sans cette étape, il serait possible de mesurer la distance entre deux détections, mais pas d'attribuer cette proximité à une paire précise de macaques.

La chaîne méthodologique peut ainsi être résumée par

$$\text{image} \longrightarrow \text{détection} \longrightarrow \text{localisation} \longrightarrow \text{identification} \longrightarrow \text{mesure de proximité.} \tag{1.23}$$

Le traitement conjoint de la localisation et de l'identification rend cette approche adaptée à l'exploitation de vidéos comportant un grand nombre d'images.

Les prédictions obtenues ne sont toutefois pas considérées comme automatiquement exactes. Elles doivent être contrôlées, corrigées et évaluées avant d'être utilisées dans la construction d'une matrice de proximité sociale. La nature des données, leur organisation et les opérations de prétraitement sont présentées dans le chapitre suivant. “‘

Chapitre 2

Données et prétraitement

Ce chapitre présente les données utilisées au cours du stage ainsi que les différentes étapes permettant de passer des enregistrements vidéo bruts à un jeu d'images annotées et exploitable par les modèles de détection et d'identification. Une attention particulière est portée à la sélection des images, à la correction manuelle des prédictions et à l'organisation des annotations produites.

2.1 Présentation et acquisition des données

Les données étudiées proviennent d'enregistrements vidéo de macaques japonais appartenant à la population de Koshima, au Japon. Le jeu de données disponible dans le cadre du projet AI-SARU représente environ quinze heures de vidéos et concerne une population d'environ quarante individus.

Ces enregistrements ont été collectés sur le terrain afin de documenter les comportements et les relations sociales entre les individus. La vidéo constitue une source d'information particulièrement adaptée à cet objectif, car elle permet d'observer simultanément plusieurs animaux, leurs déplacements et leur position relative au cours du temps.

Cependant, les vidéos brutes ne peuvent pas être utilisées directement dans une analyse statistique. Elles doivent d'abord être transformées en observations structurées comportant notamment l'identité des individus, leurs coordonnées dans l'image et les instants auxquels ils apparaissent. Le projet AI-SARU vise précisément à automatiser cette transformation grâce à une chaîne de traitement combinant détection, identification individuelle et mesure de proximité.

Les fichiers vidéo suivent une convention de nommage de la forme

`AAAAMMJJ_n`,

où `AAAA`, `MM` et `JJ` correspondent respectivement à l'année, au mois et au jour de l'enregistrement, tandis que `n` désigne le numéro de la vidéo enregistrée ce jour-là. Par exemple, le nom `20230302_1` désigne la première vidéo enregistrée le 2 mars 2023.

Les images utilisées pendant le stage étaient extraites automatiquement de ces vidéos au moyen d'un script Python. Le script parcourait chaque vidéo et enregistrait des images à intervalles réguliers. Les dossiers d'images ainsi obtenus constituaient les données d'entrée de l'interface de détection et d'identification.

La fréquence d'extraction n'était pas nécessairement identique pour toutes les vidéos. Lorsqu'un dossier contenait trop peu d'images exploitables, le paramètre contrôlant le nombre d'images extraites par seconde était augmenté. Cette adaptation permettait d'enrichir le jeu de données tout en conservant une couverture temporelle suffisante de la vidéo.

2.2 Organisation et préparation des données

Pour chaque vidéo, les images extraites étaient regroupées dans un dossier portant un nom permettant de conserver le lien avec l'enregistrement d'origine. Les noms des images contenaient également le nom de la vidéo et le numéro de la frame extraite. Un nom tel que

`20230330_9_..._frame_000035.jpg`

permet ainsi d'identifier la vidéo source et la position de l'image dans la séquence.

Après la sélection des images, le dossier correspondant était compressé au format ZIP afin d'être chargé dans l'interface de prédiction. Cette interface, développée dans le cadre du projet, était lancée depuis le terminal à l'aide d'une série de commandes spécifiques.

Trois éléments principaux devaient être fournis lors du lancement :

— le fichier `detector.pt`, correspondant au modèle chargé de détecter les visages de macaques ;
— le fichier `identificator.pt`, correspondant au modèle chargé d'attribuer une identité à chaque visage détecté ;
— le dossier d'images compressé au format ZIP.

Le premier modèle localisait les visages présents dans les images à l'aide de boîtes englobantes. Le second associait ensuite à chaque détection une identité parmi les individus connus de la population de Koshima.

À l'issue du traitement, les résultats étaient enregistrés dans un fichier JSON dont la structure est proche du format COCO. Ce fichier est organisé en trois blocs principaux :

— `images` : une entrée par image, contenant notamment son identifiant, son nom de fichier, sa hauteur et sa largeur ;
— `annotations` : une entrée par détection, contenant l'identifiant de l'image, les coordonnées de la boîte englobante (`bbox`), le score de confiance de la détection (`confidence`), l'identité retenue (`category_id` et `category_name`) et, lorsqu'elles sont disponibles, les informations de suivi temporel telles que `track_id` ;
— `categories` : la liste des identités pouvant être attribuées aux détections.

Une boîte englobante est enregistrée sous la forme

$$\texttt{bbox} = [x, y, w, h], \tag{2.1}$$

où (x, y) représente le coin supérieur gauche de la boîte, w sa largeur et h sa hauteur, en pixels.

Pour chaque détection, le champ `extended_classification` contient également les cinq identités jugées les plus probables par le modèle, notées `top1` à `top5`, ainsi que leurs scores respectifs. Ces informations permettent de visualiser le degré d'incertitude du modèle et de vérifier si l'identité réelle figure parmi les premières propositions.

Dans le fichier fourni à titre d'exemple, les images ont une résolution de 640×360 pixels. Le bloc `categories` contient 42 identités de macaques, numérotées de 0 à 41.

Le fichier JSON comprend par ailleurs un champ `proximity`, initialement vide dans les annotations examinées. Ce champ est destiné à recevoir, dans une étape ultérieure du pipeline, les informations relatives aux individus estimés proches de l'individu détecté. Le calcul de cette proximité est présenté au chapitre 3.

2.3 Nettoyage et annotation des images

Avant leur utilisation dans l'interface, les dossiers d'images faisaient l'objet d'un nettoyage manuel. Cette étape avait pour objectif d'améliorer la qualité et la représentativité du jeu de données utilisé pour l'identification des macaques.

Les images trop floues étaient supprimées lorsque le visage de l'individu ne pouvait pas être identifié de manière suffisamment fiable. Une image de mauvaise qualité peut en effet conduire à une annotation incertaine et introduire du bruit dans le jeu de données d'entraînement.

Les images fortement répétitives étaient également retirées. Lorsque plusieurs frames consécutives représentaient presque exactement la même scène et le même individu sous un angle identique, leur conservation apportait peu d'information nouvelle. Elle pouvait en revanche accentuer artificiellement la représentation de certaines situations ou de certains individus dans le jeu de données.

Le nettoyage devait toutefois rester compatible avec la nécessité de disposer d'un nombre suffisant d'exemples pour chaque individu. Lorsqu'un dossier contenait trop peu d'images après suppression des frames floues ou redondantes, la fréquence d'extraction du script Python était augmentée, puis les images étaient générées de nouveau à partir de la vidéo.

Le dossier nettoyé était ensuite compressé et chargé dans l'interface avec les deux modèles `detector.pt` et `identificator.pt`. L'interface affichait les boîtes englobantes proposées par le détecteur ainsi que l'identité considérée comme la plus probable par le modèle d'identification.

Cette première sortie constituait une préannotation automatique. Elle réduisait le temps nécessaire à l'annotation, mais ne pouvait pas être utilisée sans contrôle humain, car le modèle pouvait omettre un visage, détecter un élément ne correspondant pas à un macaque ou attribuer une identité incorrecte.

2.4 Correction et validation des détections

Chaque prédiction était examinée manuellement dans l'interface. Plusieurs types de corrections pouvaient être réalisés.

Lorsqu'un visage de macaque était visible dans l'image mais n'avait pas été détecté par le modèle, une nouvelle boîte englobante pouvait être ajoutée manuellement autour du visage. Cette situation correspond à une détection manquée par le modèle.

À l'inverse, lorsqu'une boîte englobante ne correspondait pas réellement à un visage de macaque, la fausse détection pouvait être supprimée.

Enfin, lorsque la boîte était correctement positionnée mais que l'identité proposée en première position par le modèle était incorrecte, le nom de l'individu pouvait être modifié manuellement. Les cinq propositions affichées par le modèle facilitaient parfois cette correction lorsque l'identité réelle figurait parmi les propositions secondaires.

Les corrections réalisées dans l'interface étaient ensuite enregistrées. Cette opération générait un fichier `coco_annotations.json` dans un répertoire de travail nommé `workdir`. Le fichier produit conservait les informations relatives aux images, aux boîtes englobantes et aux identités validées.

Le fichier JSON était ensuite déplacé dans le dossier correspondant aux images traitées. Cette organisation permettait de conserver ensemble les données visuelles et leurs annotations, et donc de retrouver facilement les annotations associées à chaque lot d'images.

Avant le traitement d'un nouveau dossier, le contenu du répertoire `workdir` devait être supprimé. Cette précaution évitait de mélanger les fichiers générés lors de deux traitements différents ou d'associer par erreur un fichier JSON au mauvais dossier d'images.

Les fichiers JSON corrigés avaient ainsi deux fonctions principales. D'une part, ils constituaient un jeu d'annotations validées pouvant être réutilisé pour l'entraînement ou le réentraînement des modèles. D'autre part, ils fournissaient les informations nécessaires aux étapes suivantes du pipeline, notamment les identités et les coordonnées des boîtes englobantes utilisées pour calculer la proximité entre individus.

Pour évaluer la qualité des identifications produites par le modèle, les identités prédites pouvaient également être comparées aux identités validées manuellement. Pour chaque observation, l'identité réelle et l'identité prédite étaient reportées dans un tableau de comparaison. Ce ta-

bleau constitue la vérité terrain nécessaire au calcul de la matrice de confusion et des métriques présentées au chapitre 1, section 1.3.

Les résultats numériques de cette évaluation sont présentés au chapitre 3, section **??**. Les annotations corrigées sont quant à elles utilisées comme données d'entrée du programme Python chargé d'extraire les coordonnées, de consolider les identités et de construire la matrice de proximité sociale.

Chapitre 3

Construction de la matrice de proximité sociale

3.1 Construction des observations individuelles

Les annotations corrigées présentées au chapitre précédent constituent les données d'entrée de l'analyse de proximité. Chaque annotation correspond à une détection d'un individu dans une image et est caractérisée par sa localisation, son identité prédite ainsi qu'un ensemble d'informations permettant son suivi dans la séquence vidéo.

Mathématiquement, une observation peut être représentée par le vecteur

$$o_i = (x_i, y_i, w_i, h_i, c_i, t_i, s_i)\,, \tag{3.1}$$

où (x_i, y_i) désigne les coordonnées du coin supérieur gauche de la boîte englobante, w_i et h_i sa largeur et sa hauteur, c_i l'identité attribuée par le modèle, t_i le numéro du *track* auquel appartient la détection et s_i le score de confiance associé à cette prédiction.

Les observations correspondant à un même individu apparaissant dans plusieurs images successives ne sont pas considérées comme indépendantes. Elles sont regroupées en *tracks*, c'est-à-dire en séquences temporelles décrivant le suivi d'un même individu au cours d'une portion de vidéo. Cette étape permet d'exploiter l'information temporelle afin d'obtenir une estimation plus robuste de l'identité que celle obtenue à partir d'une unique image.

Consolidation des identités

Pour chaque observation, le modèle d'identification ne fournit pas uniquement une identité unique, mais les cinq identités les plus probables accompagnées de leurs probabilités respectives. Pour un track donné, ces informations sont agrégées sur l'ensemble des images composant le suivi.

Soit t un track constitué de n_t observations. Pour chaque individu candidat k, on définit le score cumulé

$$S_t(k) = \sum_{i \in t} p_i(k), \tag{3.2}$$

où $p_i(k)$ représente le score attribué à l'identité k pour l'observation i.

L'identité retenue est celle maximisant cette quantité,

$$\widehat{c}_t = \arg\max_k S_t(k). \tag{3.3}$$

Contrairement à une décision indépendante prise image par image, cette agrégation permet de réduire l'influence d'erreurs ponctuelles dues à une occlusion, un flou de mouvement ou une

mauvaise orientation du visage. Une identité faiblement prédite sur quelques images peut ainsi être compensée par des prédictions plus fiables obtenues sur les autres images du même track.

Afin d'éviter l'utilisation de suivis trop incertains, deux critères de validation sont appliqués.

Le premier repose sur le support relatif de l'identité majoritaire

$$\text{Support}(t) = \frac{\max_k S_t(k)}{\sum_k S_t(k)}. \tag{3.4}$$

Le track n'est conservé que si

$$\text{Support}(t) \geq 0.60. \tag{3.5}$$

Autrement dit, l'identité retenue doit représenter au moins 60 % du score total cumulé des différentes identités proposées.

Le second critère impose qu'un track comporte au minimum trois observations. Cette contrainte évite de prendre une décision sur la base d'une ou deux images isolées, pour lesquelles la variabilité des prédictions est plus importante. Les paramètres effectivement utilisés lors des analyses sont un support minimal de 0,60 et un minimum de trois observations par track.

Ces deux critères permettent de privilégier la fiabilité des identifications plutôt que leur quantité. Les tracks ne satisfaisant pas ces conditions sont écartés des étapes suivantes de l'analyse afin de limiter la propagation d'erreurs vers le calcul des proximités entre individus.

Résultats de la consolidation

L'application de cette procédure aux quatre fichiers JSON analysés conduit à la construction de 4 339 tracks au total. Parmi eux, 1 014 satisfont les critères de validation et sont conservés pour la suite de l'analyse, tandis que 3 325 sont rejetés en raison d'un support insuffisant ou d'un nombre d'observations trop faible.

Ce filtrage volontairement conservateur permet de limiter les erreurs d'identification susceptibles d'affecter la construction de la matrice de proximité sociale. La qualité des observations retenues est privilégiée au nombre total de détections, afin que les distances calculées entre individus reposent sur des identités les plus fiables possible.

3.2 Extraction des coordonnées et calcul des distances

L'objectif de cette étape est de transformer les informations géométriques contenues dans les boîtes englobantes en une mesure quantitative de proximité entre individus. Chaque détection étant localisée par une boîte englobante, il est nécessaire de définir un représentant unique de sa position dans l'image avant de pouvoir calculer des distances entre individus.

Position des individus

Une boîte englobante est décrite par les coordonnées de son coin supérieur gauche (x, y) ainsi que par sa largeur w et sa hauteur h. La position de l'individu est approchée par le centre de cette boîte, défini par

$$c_x = x + \frac{w}{2}, \qquad c_y = y + \frac{h}{2}. \tag{3.6}$$

Le centre de la boîte constitue une approximation simple de la position de l'individu dans le plan de l'image. Bien qu'il ne corresponde pas exactement au centre de gravité de l'animal, il présente l'avantage d'être directement déterminé à partir des sorties du détecteur et d'être calculable de manière identique pour toutes les observations.

Distance euclidienne

Pour deux individus a et b détectés simultanément dans une même image, la distance entre leurs centres est calculée à l'aide de la distance euclidienne

$$d_{ab} = \sqrt{(c_{x,a} - c_{x,b})^2 + (c_{y,a} - c_{y,b})^2}. \tag{3.7}$$

Cette quantité mesure l'écart apparent entre les deux individus dans le plan de l'image. Cependant, elle dépend directement de la perspective de la caméra : une même distance physique peut produire des distances très différentes en pixels selon que les individus sont proches ou éloignés de l'objectif.

Une normalisation est donc nécessaire afin de rendre comparables les distances calculées dans différentes situations d'observation.

Normalisation par la taille apparente

La hauteur de la boîte englobante constitue un indicateur de l'échelle de l'individu dans l'image. Plus un individu est éloigné de la caméra, plus sa boîte apparaît petite. À l'inverse, un individu proche de la caméra possède généralement une boîte de plus grande hauteur.

Toutefois, la taille apparente dépend également de l'âge de l'animal. Les jeunes macaques étant naturellement plus petits que les adultes, une correction est appliquée afin de limiter ce biais.

La hauteur corrigée est définie par

$$h^{\text{corr}} = h \times \alpha(\text{âge}), \tag{3.8}$$

où $\alpha(\text{âge})$ est un facteur correctif dépendant de la classe d'âge attribuée à l'individu.

La distance normalisée est alors obtenue par

$$d_{ab}^{\text{norm}} = \frac{d_{ab}}{\max\left(h_a^{\text{corr}}, h_b^{\text{corr}}\right)}. \tag{3.9}$$

Cette normalisation permet d'exprimer la distance relativement à la taille apparente des individus plutôt qu'en nombre de pixels. Les distances deviennent ainsi plus comparables entre vidéos filmées à des distances différentes de la caméra.

Contrôle des différences de profondeur

Deux individus peuvent sembler proches dans l'image alors qu'ils sont en réalité situés à des profondeurs très différentes. Pour limiter ce phénomène de perspective, une seconde vérification est effectuée à partir de la taille des boîtes corrigées.

Le rapport entre les aires corrigées est défini par

$$r_{ab} = \frac{\max\left(A_a^{\text{corr}}, A_b^{\text{corr}}\right)}{\min\left(A_a^{\text{corr}}, A_b^{\text{corr}}\right)}, \tag{3.10}$$

où

$$A^{\text{corr}} = w \times h^{\text{corr}}. \tag{3.11}$$

Lorsque ce rapport devient trop important, les deux individus sont supposés se trouver à des profondeurs incompatibles et la paire est exclue de l'analyse.

Le seuil retenu est

$$r_{ab} \leq 3, \tag{3.12}$$

ce qui correspond à la valeur utilisée lors du calcul de la matrice de proximité.

Définition d'une proximité

Une paire d'individus est considérée comme proche lorsque deux conditions sont simultanément vérifiées :

$$d_{ab}^{\text{norm}} \leq \tau_{\text{dist}} \tag{3.13}$$

avec

$$\tau_{\text{dist}} = 3,$$

et

$$r_{ab} \leq \tau_{\text{ratio}}, \tag{3.14}$$

avec

$$\tau_{\text{ratio}} = 3.$$

Ces deux critères sont complémentaires. Le premier traduit une proximité géométrique entre les individus, tandis que le second permet d'écarter les situations dans lesquelles cette proximité apparente pourrait être expliquée par un effet de perspective. Seules les paires satisfaisant simultanément ces deux conditions sont retenues pour la construction de la matrice de proximité sociale.

3.3 Construction de la matrice de proximité sociale

Les critères de proximité définis à la section précédente permettent de déterminer, pour chaque image, si deux individus sont considérés comme proches ou non. L'objectif est maintenant d'agréger ces observations afin d'obtenir une mesure globale de la proximité sociale entre chaque paire d'individus.

Cette construction est réalisée en deux étapes. Dans un premier temps, un score de proximité est calculé indépendamment pour chaque vidéo. Dans un second temps, ces scores sont combinés afin d'obtenir une matrice unique décrivant l'ensemble des relations de proximité observées dans les données.

Calcul d'un score de proximité par vidéo

Considérons une vidéo v et deux individus a et b. Les deux individus ne sont pas nécessairement visibles dans toutes les images de la vidéo. Seules les images dans lesquelles ils sont simultanément détectés et satisfont les critères de validité définis précédemment sont retenues.

On note

— $N_{\text{co}}^{(v)}(a,b)$ le nombre de frames où les deux individus sont simultanément observés ;

— $N_{\text{prox}}^{(v)}(a,b)$ le nombre de ces frames pour lesquelles les deux individus sont considérés comme proches.

Le score de proximité associé à la vidéo v est alors défini par

$$S_v(a,b) = \frac{N_{\text{prox}}^{(v)}(a,b)}{N_{\text{co}}^{(v)}(a,b)}. \tag{3.15}$$

Ce score correspond à la proportion d'observations où les deux individus sont en situation de proximité parmi toutes les observations où ils apparaissent ensemble.

Par construction,

$$0 \leq S_v(a,b) \leq 1. \tag{3.16}$$

Une valeur proche de 1 indique que les deux individus sont presque toujours observés côte à côte lorsqu'ils apparaissent dans une même vidéo, tandis qu'une valeur proche de 0 traduit une faible proximité spatiale.

Agrégation des vidéos

Les différentes vidéos disponibles ne possèdent pas toutes la même durée ni le même nombre d'observations exploitables. Une moyenne arithmétique simple attribuerait le même poids à une vidéo contenant seulement quelques dizaines d'observations qu'à une vidéo beaucoup plus riche en informations.

Afin de tenir compte de cette hétérogénéité, chaque vidéo est pondérée en fonction du nombre de frames valides utilisées pour calculer son score.

Le poids attribué à la vidéo v est défini par

$$w_v = \min\left(N_{\text{co}}^{(v)}, w_{\max}\right), \tag{3.17}$$

où $N_{\text{co}}^{(v)}$ représente le nombre de codétections valides dans la vidéo et $w_{\max}$ un plafond fixé à 900 observations. Cette limitation évite qu'une vidéo très longue domine excessivement l'estimation finale. Les paramètres effectivement utilisés lors des analyses correspondent à $w_{\max} = 900$.

La matrice globale de proximité est ensuite obtenue par une moyenne pondérée des scores vidéo :

$$\widehat{M}_{ab} = \frac{\sum_v w_v \, S_v(a,b)}{\sum_v w_v}. \tag{3.18}$$

Ainsi, les vidéos apportant davantage d'observations contribuent davantage à l'estimation, tout en restant limitées par le poids maximal autorisé.

Interprétation statistique

Le coefficient $\widehat{M}_{ab}$ peut être interprété comme un estimateur empirique de la fréquence de proximité entre les individus a et b au sein de l'ensemble des vidéos analysées.

Plus sa valeur est élevée, plus les deux individus sont observés à proximité l'un de l'autre de manière répétée. À l'inverse, une valeur faible indique que les situations de proximité sont rares malgré la présence simultanée des deux individus.

Contrairement à une distance métrique, cette quantité mesure une intensité de proximité et non une séparation spatiale. Deux individus présentant une valeur élevée dans la matrice sont donc interprétés comme entretenant une relation de proximité plus fréquente.

Propriétés de la matrice

La matrice $\widehat{M}$ possède plusieurs propriétés importantes.

Tout d'abord, elle est symétrique :

$$\widehat{M}_{ab} = \widehat{M}_{ba}, \tag{3.19}$$

puisque la proximité entre les individus a et b est indépendante de l'ordre dans lequel ils sont considérés.

Les coefficients appartiennent également à l'intervalle

$$0 \leq \widehat{M}_{ab} \leq 1, \tag{3.20}$$

car ils résultent d'une moyenne pondérée de proportions, elles-mêmes comprises entre 0 et 1.

Par ailleurs, les éléments diagonaux ne sont pas interprétés, puisqu'un individu est toujours situé à une distance nulle de lui-même. Enfin, certaines cases de la matrice peuvent être absentes lorsqu'une paire d'individus n'a jamais été simultanément observée dans les vidéos disponibles.

La matrice ainsi obtenue constitue la synthèse quantitative des proximités détectées automatiquement à partir des séquences vidéo. Elle servira de base à la comparaison statistique avec la matrice issue des observations de terrain, présentée au chapitre suivant.

Chapitre 4

Comparaison statistique des matrices

4.1 Méthodologie de comparaison des matrices

Les entrées de la matrice $\hat{M}$ (et de la matrice de référence M^*) ne sont pas indépendantes entre elles : la ligne associée à un individu a particulièrement sociable sera globalement élevée sur toute la ligne, car les valeurs $\hat{M}_{ab}$ et $\hat{M}_{ac}$ partagent la même dépendance à a. Un test de corrélation classique (Pearson), qui suppose l'indépendance des observations, ne peut donc pas être appliqué directement entre les entrées des deux matrices. Une méthode adaptée à cette structure de dépendance est nécessaire : le test de Mantel.

4.2 Présentation théorique du test de Mantel

Le **test de Mantel** [**?**] est spécifiquement conçu pour comparer deux matrices de distance ou de proximité définies sur le même ensemble d'unités (ici, les K individus).

Statistique de test. On considère la corrélation (par exemple de Pearson) entre les entrées des deux matrices, restreinte aux paires distinctes (a, b), $a \neq b$:

$$Z_{\text{obs}} = \text{corr}\big(\{\hat{M}_{ab}\}_{a<b},\ \{M^*_{ab}\}_{a<b}\big). \tag{4.1}$$

Hypothèse nulle et test par permutation. L'hypothèse nulle H_0 postule l'absence d'association entre les deux structures de proximité. Comme les entrées d'une même matrice ne sont pas indépendantes (une ligne entière dépend de la sociabilité globale d'un individu), la distribution théorique usuelle de la statistique de corrélation ne s'applique pas. On construit donc la distribution de Z sous H_0 par **permutation** :

1. on permute aléatoirement l'ordre des individus (lignes et colonnes simultanément) dans l'une des deux matrices, par exemple M^*, donnant M^*_π pour une permutation π ;
2. on recalcule la statistique de corrélation Z_π entre $\hat{M}$ et M^*_π ;
3. on répète l'opération un grand nombre de fois (typiquement 999 ou 9999 permutations), donnant une distribution empirique $\{Z_\pi\}$ sous H_0.

La p-valeur empirique est alors la proportion de permutations pour lesquelles Z_π est au moins aussi extrême que Z_{obs} :

$$p = \frac{1 + \#\{\pi : |Z_\pi| \geq |Z_{\text{obs}}|\}}{1 + \text{nombre de permutations}}. \tag{4.2}$$

4.3 Application du test de Mantel et résultats

Vérification des conditions d'application.

— Les deux matrices doivent être définies sur le même ensemble d'individus, avec le même ordre de lignes/colonnes avant permutation.
— Le nombre de permutations doit être suffisant pour estimer précisément la p-valeur (au minimum quelques centaines).
— Les valeurs manquantes (paires jamais co-détectées dans $\hat{M}$) doivent être traitées explicitement (exclusion de la paire dans les deux matrices, ou imputation à justifier).
— Le test de Mantel suppose que la structure de dépendance interne à chaque matrice est correctement neutralisée par la permutation conjointe des lignes/colonnes – ce qui est le cas ici, la permutation appliquée à un individu déplace simultanément toute sa ligne et sa colonne.

Résultats obtenus.

4.4 Interprétation des résultats

Chapitre 5

Discussion et perspectives

5.1 Discussion des résultats

5.2 Limites et conditions d'application des méthodes

5.3 Perspectives d'amélioration

Conclusion générale

Annexe A

Annexes

A.1 Extraits de code

```
def evaluate_pair_in_frame(a, b, dist_thresh_norm, size_ratio_thresh):
    dist_norm = distance(a, b) / max(a["corrected_h"], b["corrected_h"])
    size_ratio = max(a["aire"], b["aire"]) / min(a["aire"], b["aire"])
    close = (dist_norm <= dist_thresh_norm) and (size_ratio <=
        size_ratio_thresh)
    return close
```

A.2 Figures complémentaires

A.3 Tableaux complémentaires